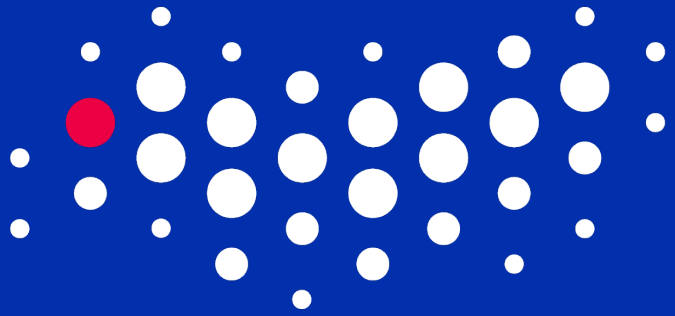

ITMO UNIVERSITY

Обнаружение проблем производительности в программах на языке программирования Kotlin с использованием статического анализа кода

Петухов Виктор

Университет ИТМО

Кафедра Компьютерных технологий

Предметная область

- Кодовая аномалия — нетипичный по тем или иным меркам код
- Разработчики Kotlin хотят видеть экзотические примеры использования языка (аномалии)
- По их мнению, такие примеры помогут отслеживать производительность компилятора и выявить проблемы в кодогенерации или оптимизациях

Объекты анализа

- PSI дерево разбора Kotlin-кода
- JVM байт-код (from Kotlin)
- JVM back-end IR (разрабатывается)
- Kotlin/Native IR (уже есть, можно пробовать)
- LLVM-код (from Kotlin, можно пробовать)
- Javascript (from Kotlin, можно пробовать)

PSI дерево — конкретное синтаксическое дерево (CST)

Потенциальная польза аномалий на PSI

- На таком коде компилятор языка либо не изучен, либо малоизучен => можно использовать аномалии как тесты компилятора (например, на производительность)

- Можно смотреть на решаемую задачу и делать выводы о недостатках в дизайне языка, о надобности разработки новых конструкций

Потенциальная польза аномалий на байт-коде

- Польза в составе условных аномалий
- Условная аномалия — аномалия на байт-коде, но не аномалия на PSI, и наоборот
- Можно пробовать давать оценку работе кодогенератора и оптимизаций компилятора

Потенциальная польза условных аномалий по байт-коду

- Негативный случай: Было сгенерировано больше байт-кода, чем ожидалось
  - Возможные проблемы в кодогенерации
- Позитивный случай: Удачная реализация некоторой конструкции языка
  - Для большого кол-ва низкоуровневых действий удалось придумать элегантную конструкцию в языке
  - Тоже интересно смотреть: можно перенять опыт реализации таких конструкций

Потенциальная польза условных аномалий по PSI

- Сложное PSI свернулось в простой байт-код
- Вероятно, можно говорить об удачно сработавших оптимизациях компилятора
- Можно пробовать отслеживать эффективность оптимизаций, проводя на таких примерах регрессионное тестирование компилятора

Постановка задачи

- Аномалию сложно описать в терминах классических алгоритмов, «нетипичность» может быть выражена в самых разных свойствах
- Будем решать задачу обнаружения аномалий, уже поставленную в области машинного обучения
- Предварительно будем осуществлять факторизацию исходного и байт-кода
- Будем собирать два набора данных: для простых аномалий и условных

Сбор данных

- GitHub — одно из крупнейших хранилищ открытого Kotlin-кода — будем использовать его для сбора кода
- 47 тыс. репозиториев с основным языком — Kotlin
- Байт-код будем собирать из файлов готовых сборок репозитория
- Результаты:
  - Для малого датасета: собрано **40 тыс.** файлов с исходных кодом и **8 тыс.** файлов с байт-кодом
  - Для большого датасета: собрано **930 тыс.** файлов с исходным кодом на Kotlin и **63 тыс.** файлов с байт-кодом

Сопоставление исходного кода и байт-кода

- Для дальнейшего формирования условных аномалий нужно иметь сопоставленные файлы исходного кода файлам с байт-кодом

- Был разработан соответствующий инструмент:
  - Достает из мета-информации class-файлов имя пакета и исходника
  - Достает из PSI имя пакета
  - Сопоставляет имена пакетов и файлов

Векторизация кода

- Векторное представление исходного и байт-кода будем формировать путем разложения на n-граммы (uni-, bi- и 3-граммы)
- Автокодирование позволяет извлекать неявные признаки, которые может быть сложно извлечь вручную и интерпретировать
- Результаты:
  - Для большого датасета: **11 тыс.** n-gram по PSI и **111 тыс.** n-gram по байт-коду
  - Для малого датасета: **5 тыс.** n-gram по PSI и **79 тыс.** n-gram по байт-коду

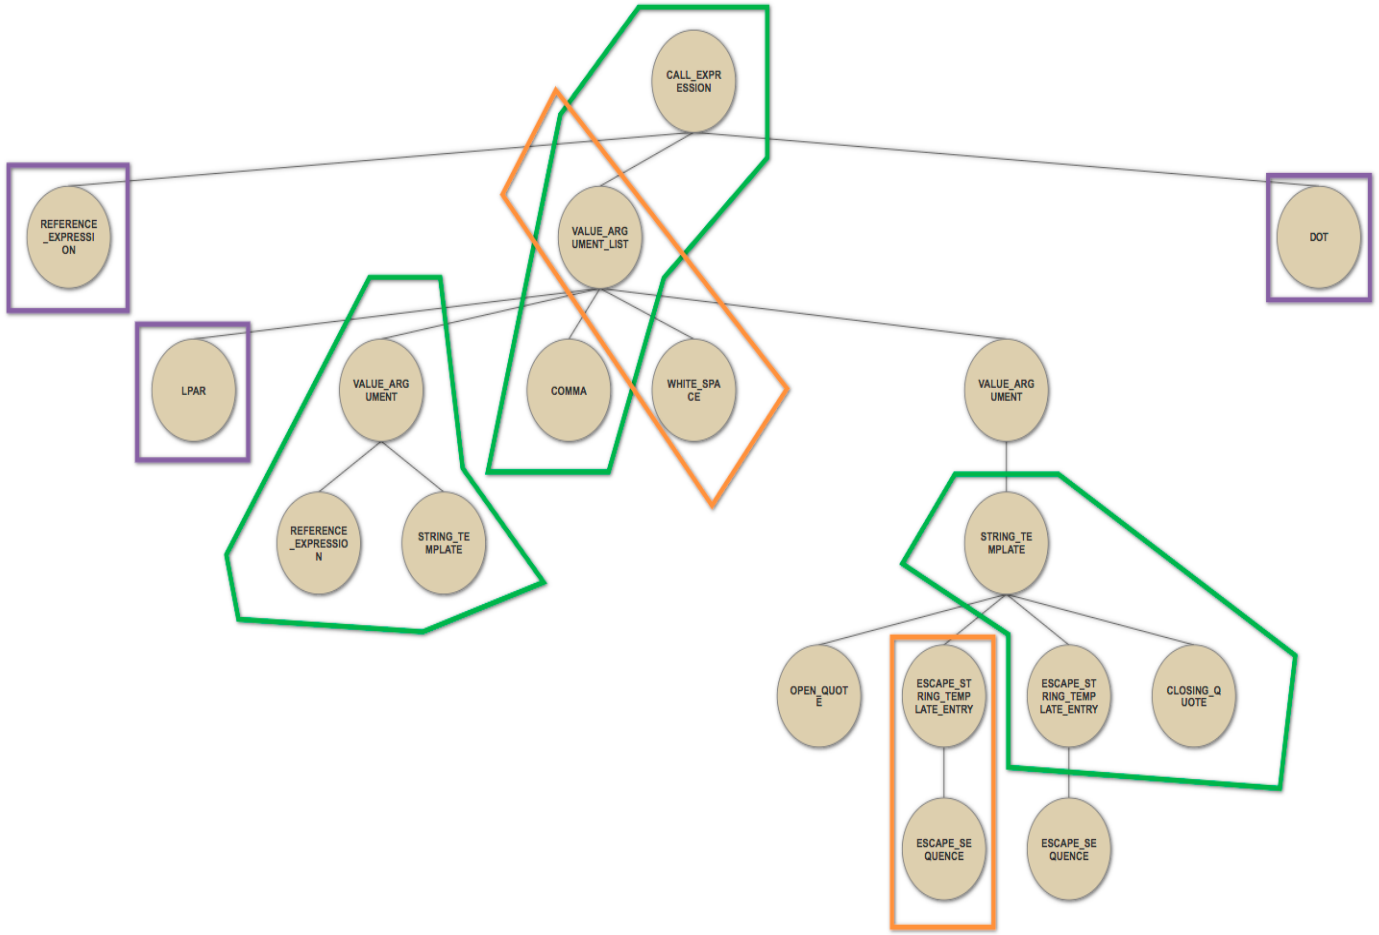

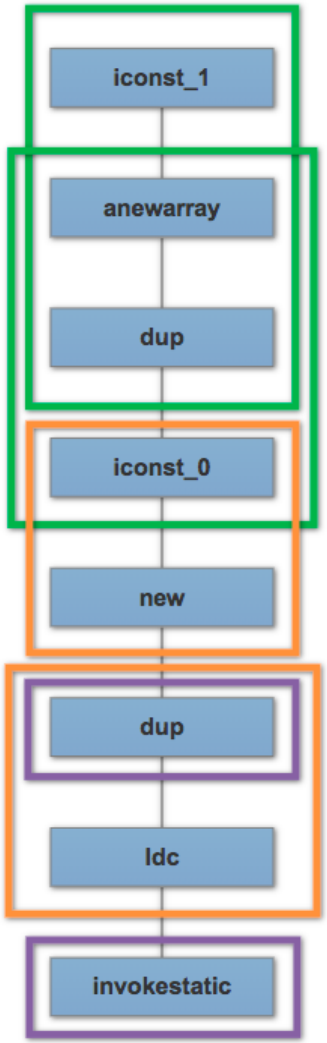

Векторизация PSI

Векторизация байт-кода

Методы решения задачи обнаружения аномалий

- Метод опорных векторов с одним классом (OC SVM)
- Методы, основанные на кластеризации (например, k-means)
- Статистические методы
- Репликаторные нейросети, автоэнкодеры

Автоэнкодер

- Для решения задачи был выбран автоэнкодер:
  - Обучение без учителя (примеров аномалий изначально нет)
  - Не двоичный выход — ошибку восстановления можно трактовать как «степень аномальности»
  - Встроенные механизмы сокращения размерности — можно формировать для этого отдельные слои в архитектуре сети: признаков очень много

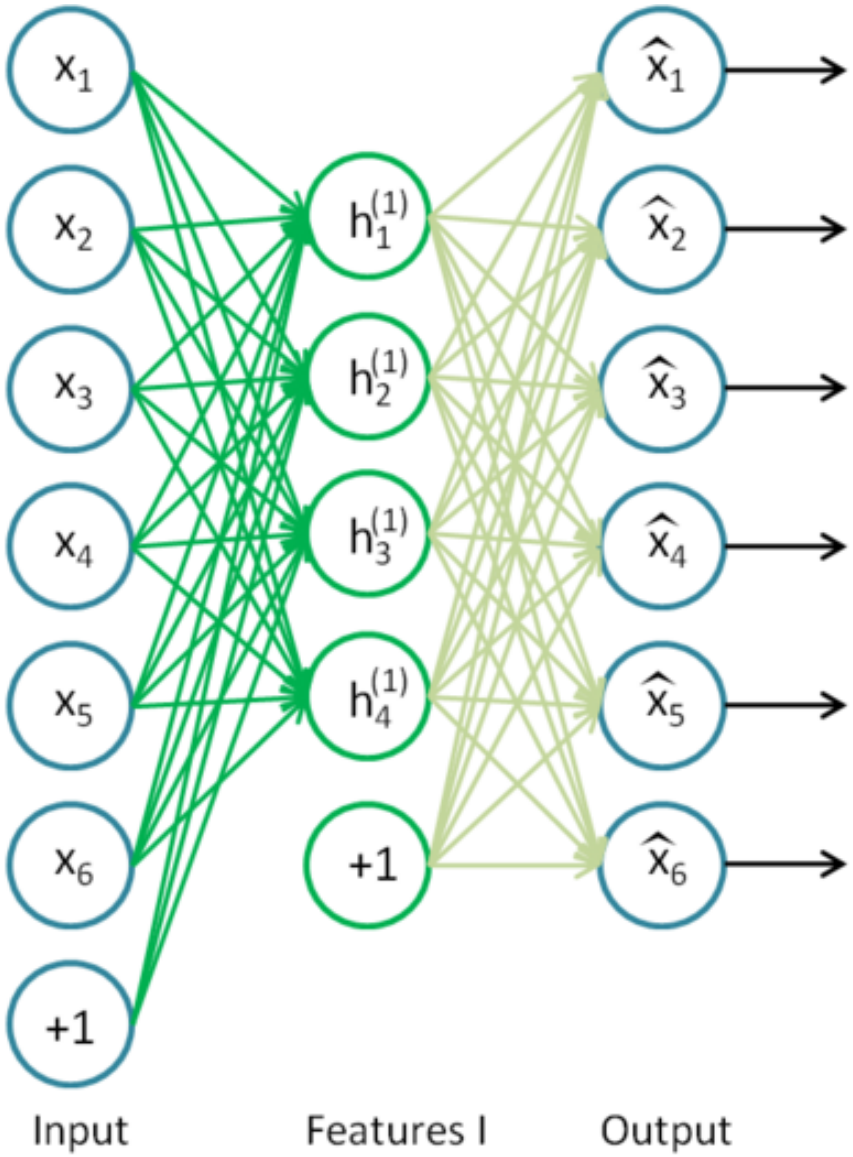

- Простая архитектура — один скрытый слой
- Несколько экспериментов с коэффициентом сжатия **0.8** и **0.5**

Отбор признаков

- На байт-коде n-грамм очень много, нужно сокращать размерность
- Был разработан инструмент для отсечения ТОПа частотного списка n-грамм
- Предположительно, такие n-граммы должны вносить минимальный вклад в формирование аномалий
- Результаты:
  - По большому датасету: отобрано **25 тыс.** n-грамм
  - По малому датасету: отобрано **2.8 тыс.** n-грамм

Результаты

- По результатам работы автоэнкодера были вычислены евклидовы расстояния между входными и выходными векторами
- Расстояния трактовались как «степени аномальности»
- В качестве аномалий были отобраны примеры, у которых расстояние от входного вектора до выходного отклонялось от среднего более чем на 3-сигма или 5-сигма
- Итого было получено аномалий:
  - По большому датасету: **4924** по PSI и **456** по байт-коду
  - По малому датасету: **362** по PSI и **151** по байт-коду

Классификация аномалий

- Найденные аномалии по малому датасету были вручную классифицированы
- По **513** аномалиям было выделено **30** классов:
  - В **25** классах присутствовали аномалии по байт-коду
  - В **10** классах присутствовали аномалии по PSI
  - В **10** классах присутствовали аномалии по PSI и байт-коду

http://victor.am — список всех аномалий

big companion object

many safe calls

many root function definitions

many var or fun definitions

big and complex enums

big init method in bytecode

many similar call expressions

big static arrays or map

nested calls

big multiline strings

big code hierarchy

many square bracket annotations

long enumerations

long calls chain

many concatenations

many consecutive arithmetic expressions

many not null assertion operators

many case in when

complex or long logical expressions

many type reified params

many function arguments

many delegate properties

many inline functions

big constants set

many nested structures

many if statements

many generic parameters

big methods

many loops

many literal strings

many assignment statements

Сбор экспертных оценок

- Была разработана функциональность на веб-сайте для оценивания классов и аномалий разработчиками Kotlin

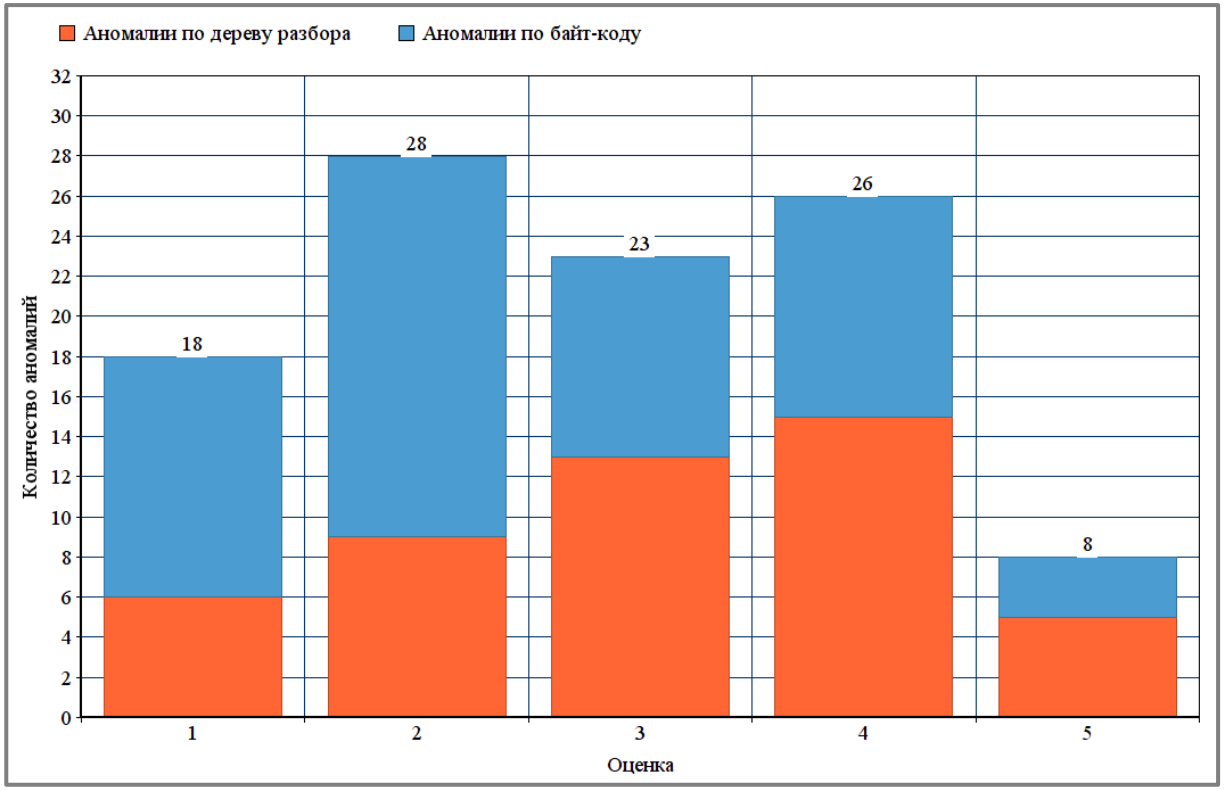

- Среднее по классам — **2.462**
- Среднее по аномалиям — **2.786**
  - По PSI — **3.083**
  - По байт-коду — **2.527**

- **12** классов с оценками 4 и 5
- **34** аномалии с оценками 4 и 5

Пример аномалии из класса Many generic parameters по дереву разбора с оценкой 5

```
@Suppress("UNCHECKED_CAST")
fun <V1, V2, V3, V4, V5, V6, V7, V8, V9, V10, V11, V12, V13, V14, V15, V16, V17, V18, V19, V20, E> concreteCombine(p1: Promise<V1, E>,
                                                                                                                   p2: Promise<V2, E>,
                                                                                                                   p3: Promise<V3, E>,
                                                                                                                   p4: Promise<V4, E>,
                                                                                                                   p5: Promise<V5, E>,
                                                                                                                   p6: Promise<V6, E>,
                                                                                                                   p7: Promise<V7, E>,
                                                                                                                   p8: Promise<V8, E>,
                                                                                                                   p9: Promise<V9, E>,
                                                                                                                   p10: Promise<V10, E>,
                                                                                                                   p11: Promise<V11, E>,
                                                                                                                   p12: Promise<V12, E>,
                                                                                                                   p13: Promise<V13, E>,
                                                                                                                   p14: Promise<V14, E>,
                                                                                                                   p15: Promise<V15, E>,
                                                                                                                   p16: Promise<V16, E>,
                                                                                                                   p17: Promise<V17, E>,
                                                                                                                   p18: Promise<V18, E>,
                                                                                                                   p19: Promise<V19, E>,
                                                                                                                   p20: Promise<V20, E>):Promise<Tuple20<V1, ... (and 19 similar parameters)
    val deferred = deferred<Tuple20<V1, V2, V3, V4, V5, V6, V7, V8, V9, V10, V11, V12, V13, V14, V15, V16, V17, V18, V19, V20>, E>()

    val results = AtomicReferenceArray<Any?>(20)
    val successCount = AtomicInteger(20)

    fun createTuple(): Tuple20<V1, V2, V3, V4, V5, V6, V7, V8, V9, V10, V11, V12, V13, V14, V15, V16, V17, V18, V19, V20> {
        return Tuple20(
                results.get(0) as V1,
                results.get(1) as V2,
                (and 19 similar expressions)
```

Пример аномалии из класса Long enumerations по дереву разбора с оценкой 5

```
@Suppress("PLATFORM_CLASS_MAPPED_TO_KOTLIN")
    override fun predicate(fromType: Type, toType: Type): Boolean {
        val fromErased = fromType.erasedType()
        return when {
            String::class.isAssignableFrom(fromType) -> when (toType) {
                String::class.java,
                Short::class.java, java.lang.Short::class.java,
                Byte::class.java, java.lang.Byte::class.java,
                Int::class.java, Integer::class.java,
                Long::class.java, java.lang.Long::class.java,
                Double::class.java, java.lang.Double::class.java,
                Float::class.java, java.lang.Float::class.java,
                BigDecimal::class.java,
                BigInteger::class.java,
                CharSequence::class.java,
                ByteArray::class.java,
                Boolean::class.java, java.lang.Boolean::class.java,
                File::class.java,
                URL::class.java,
                URI::class.java -> true
                else -> {
                    val toErased = toType.erasedType()
                    toErased.isEnum
                }
            }
            CharSequence::class.isAssignableFrom(fromType) -> when (toType) {
                CharSequence::class.java,
                String::class.java,
                ByteArray::class.java -> true
                else -> false
            }
            Number::class.isAssignableFrom(fromType) -> when (toType) {
                Short::class.java, java.lang.Short::class.java,
                Byte::class.java, java.lang.Byte::class.java,
                Int::class.java, Integer::class.java,
            (and 9 more similar when statements)
```

Формирование условных аномалий

- Всем аномалиям по байт-коду были сопоставлены «степени аномальности» по PSI и наоборот
- Были вычислены разности «степеней аномальности» и получен отсортированный по ним список
- Как условные аномалии были помечены примеры с отклонением от СКО/4 («голова» и «хвост» списков):
  - **6** условных аномалий по байт-коду
  - **32** условных аномалии по PSI

Пример условной аномалии по байт-коду 1

```
class ConfigModel(val configs: Config) : ViewModel() {
    val ip = bind { configs.ipProperty }
    val dataBase = bind { configs.dataBaseProperty }
    val rootUser = bind { configs.rootUserProperty }
    val password = bind { configs.passwordProperty }
    val tableName = bind { configs.tableNameProperty }
    val entityName = bind { configs.entityNameProperty }
    val entityPackage = bind { configs.entityPackageProperty }
    val mapperPackage = bind { configs.mapperPackageProperty }
    val servicePackage = bind { configs.servicePackageProperty }
}
```

```
{
  "getIp" : [ "aload_0", "getfield", "areturn" ],
  "getDataBase" : [ "aload_0", "getfield", "areturn" ],
  "getRootUser" : [ "aload_0", "getfield", "areturn" ],
  "getPassword" : [ "aload_0", "getfield", "areturn" ],
  "getTableName" : [ "aload_0", "getfield", "areturn" ],
  "getEntityName" : [ "aload_0", "getfield", "areturn" ],
  "getEntityPackage" : [ "aload_0", "getfield", "areturn" ],
  "getMapperPackage" : [ "aload_0", "getfield", "areturn" ],
  "getServicePackage" : [ "aload_0", "getfield", "areturn" ],
  "getConfigs" : [ "aload_0", "getfield", "areturn" ],
  "<init>" : [ "aload_1", "ldc", "invokestatic", "aload_0", ... (4428 instructions)
}
```

Планы

- Автоматическая классификация аномалий, фокус на обнаружение новых классов
- Проведение экспериментов с оценкой влияния привнесенных в язык фич (с перспективной разработки тестов на такой системе)
- Проведение экспериментов по отслеживанию эффективности оптимизаций компилятора
- Проведение экспериментов с анализом не расстояний между векторами, а векторов разностей (и с классификацией после через DBScan), и попробовать выявлять происхождение аномалий (n-граммы)
- Проведение аналогичного исследования в Kotlin/Native, Kotlin/JS и на IR

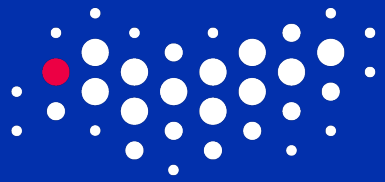

ITMO UNIVERSITY

Спасибо за внимание!

Петухов Виктор

Кафедра Компьютерных технологий

Университет ИТМО

i@victor.am

http://victor.am

Санкт-Петербург, 2018