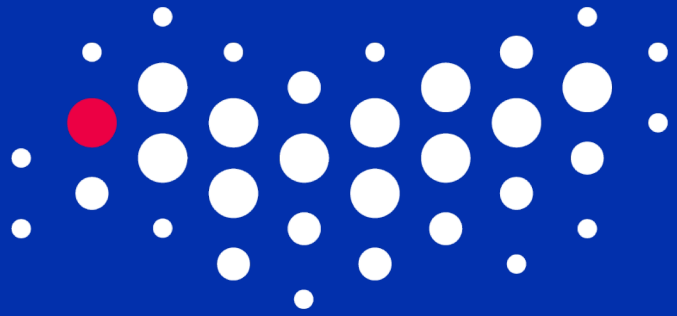

ITMO UNIVERSITY

Обнаружение проблем производительности в программах на языке программирования Kotlin с использованием статического анализа кода

Петухов Виктор, гр. M4238

Руководитель: Фильченков А. А., к. ф-м. н., доц. каф. КТ

Консультант: Поваров Н.И., аналитик, ООО «Интеллиджей ЛАБС»

Рецензент: Брыксин Т.А., к.т.н., доц. каф. системного программирования СПбГУ

Кафедра Компьютерных технологий

Предметная область

- Производительность в разработке ПО — одно из важнейших нефункциональных требований
- Часть проблем производительности может заключаться в компиляторе языка — неоптимальной кодогенерации или проблемах в оптимизациях
- Разработчики компилятора Kotlin для их обнаружения хотят видеть экзотические примеры использования языка (аномалии) с целью тестирования компилятора на них

Постановка задачи

- Аномалию сложно описать в терминах классических алгоритмов, «нетипичность» может быть выражена в самых разных свойствах
- Будем решать задачу обнаружения аномалий, уже поставленную в области машинного обучения
- Таким образом, исходная задача состоит из:
  - задачи факторизации кода,
  - задачи поиска аномалий.

Существующие решения

- Graph-based Mining of Multiple Object Usage Patterns
- Detecting Object Usage Anomalies
- A Fast Automaton-Based Method for Detecting Anomalous Program Behaviors
- Детектор аномалий в программах на языке Kotlin

Цели исследования

- Разработать решение, позволяющее на некотором наборе исходного кода на Kotlin и байт-кода осуществлять поиск аномалий
- Провести ряд экспериментов, направленных на получение большего числа аномалий
- Произвести сравнение полученных результатов между собой и с результатами похожей работы
- Получить экспертные оценки результатов

Научная новизна

- …заключается в применении и адаптации алгоритмов обнаружения аномалий и факторизации кода для тестирования производительности компилятора и дальнейшего возможного обнаружения проблем в ней (путем поиска экзотических примеров использования языка)

Анализ задачи: факторизация кода

- Разные подходы к извлечению признаков:
  - ручное извлечение,
  - автокодирование.
- Будем использовать автокодирование путем разложения на n-граммы — оно позволяет извлекать неявные признаки:
  - Их сложно извлекать вручную и интерпретировать человеку;
  - Но они могут вносить существенный вклад в формирование аномалий.
- Произведем сравнение с ручным извлечением, используемым в похожей работе

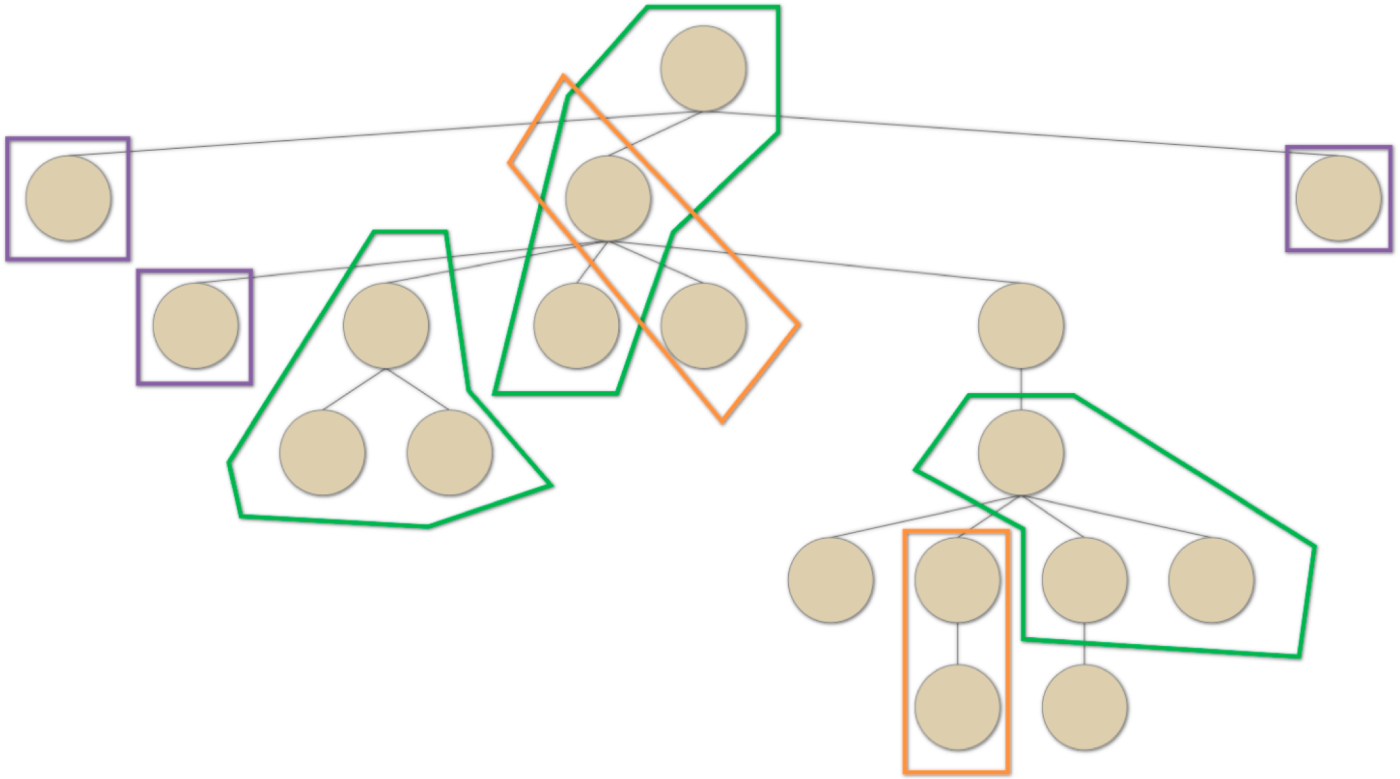

Факторизация дерева разбора

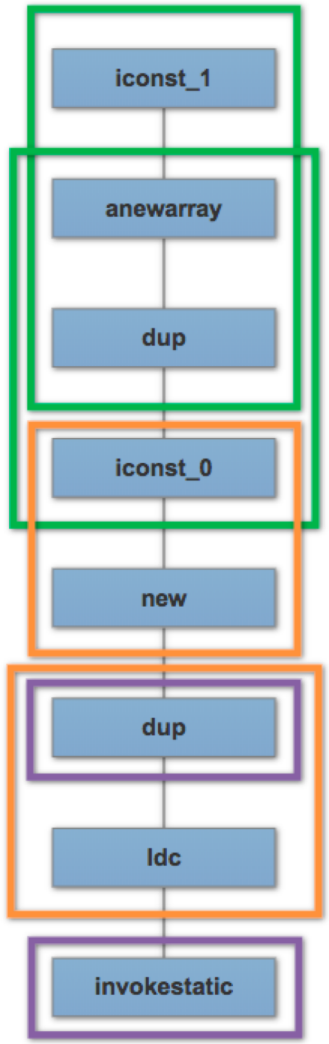

Факторизация байт-кода

Анализ задачи: обнаружение аномалий

- Существующие техники:
  - OC SVM,
  - local outlier factor (k-ближайших соседей),
  - изолирующий лес,
  - elliptic envelope (статистические методы),
  - автоэнкодеры.
- Будем пробовать использовать все перечисленные методы с последующим сравнением результатов
- Предположительно, часть методов использовать не удастся из-за очень большого числа признаков

Разработка решения

- Было разработано решение, выполняющее следующие задачи:
  - Сбор исходного кода на Kotlin и байт-кода с GitHub;
  - Извлечение дерева разбора и списка JVM инструкций;
  - Факторизация кода путем его разложения на униграммы, биграммы и триграммы;
  - Обнаружение аномалий.
- На выходе — список файлов с исходным кодом и байт-кодом, помеченных как аномалии (с численной оценкой аномальности)

Эксперименты: сбор данных

- Было собрано **930 тыс.** файлов с исходным кодом на Kotlin
- Было собрано **63 тыс.** файлов с JVM байт-кодом

Эксперименты: факторизация кода

Таблица 1. Количество извлеченных n-грамм для разных параметров

Параметры / Тип исходных данных	$n_{max} = 3$ $distance_{max} = 3$ тип $= 1$ Вариант 1	$n_{max} = 3$ $distance_{max} = 3$ тип $= 2$ Вариант 2	$n_{max} = 3$ $distance_{max} = 0$ тип $= 2$ Вариант 3
Дерево разбора	4 тыс.	61 тыс.	11 тыс.
Байт-код	180 тыс.	180 тыс.	111 тыс.

- тип $= 1$ — учёт связей только типа «родитель-ребенок»
- тип $= 2$ — учёт произвольных связей

- $distance$ — максимальное расстояние между двумя узлами в n-грамме (плавающее окно)

Эксперименты: поиск аномалий

- Из предложенных методов в связи с ресурсными ограничениями удалось использовать лишь автоэнкодер
- По результатам его работы были вычислены ошибки восстановления — евклидовы расстояния между входными и выходными векторами
- Данные расстояния трактовались как оценки аномальности
- Аномалиями считались примеры с оценками, отклоняющимися от среднего более чем на 3 СКО

Эксперименты: поиск аномалий

Таблица 2. Количество полученных аномалий для разных параметров с набором данных 1

Тип исходных данных / Пар-ры	$dim = 0.25$ набор данных $= 1$	$dim = 0.5$ набор данных $= 1$	$dim = 0.75$ набор данных $= 1$
Дерево-разбора	350	338	320
Байт-код	58	56	55

Таблица 3. Количество полученных аномалий для разных параметров с набором данных 2

Тип исходных данных / Пар-ры	$dim = 0.25$ набор данных $= 2$	$dim = 0.5$ набор данных $= 2$	$dim = 0.75$ набор данных $= 2$
Дерево-разбора	751	712	680
Байт-код	58	56	55

Таблица 4. Количество полученных аномалий для разных параметров с набором данных 3

Тип исходных данных / Пар-ры	$dim = 0.25$ набор данных $= 3$	$dim = 0.5$ набор данных $= 3$	$dim = 0.75$ набор данных $= 3$
Дерево-разбора	1505	1351	1306
Байт-код	126	120	120

Сравнение результатов

Таблица 5. Количество новых обнаруженных аномалий по результатам разных экспериментов

Набор аномалий	$N_d = 1$ $N_v = 1$	$N_d = 1$ $N_v = 2$	$N_d = 1$ $N_v = 3$	$N_d = 2$ $N_v = 1$	$N_d = 2$ $N_v = 2$	$N_d = 2$ $N_v = 3$	$N_d = 3$ $N_v = 1$	$N_d = 3$ $N_v = 2$	$N_d = 3$ $N_v = 3$
$N_d = 1, N_v = 1$		1 / 0	2 / 0	428 / 0	389 / 0	356 / 0	**1150 / 65**	998 / 60	955 / 59
$N_d = 1, N_v = 2$	11 / 2		0 / 0	412 / 2	372 / 0	340 / 0	**1160 / 64**	1105 / 59	965 / 58
$N_d = 1, N_v = 3$	28 / 3	18 / 1		429 / 3	390 / 1	357 / 0	**1180 / 68**	1026 / 58	970 / 61
$N_d = 2, N_v = 1$	27 / 0	1 / 0	2 / 0		4 / 0	5 / 0	**725 / 65**	589 / 60	542 / 59
$N_d = 2, N_v = 2$	27 / 2	2 / 0	2 / 0	35 / 2		2 / 0	**780 / 64**	631 / 59	582 / 58
$N_d = 2, N_v = 3$	26 / 3	2 / 1	3 / 0	66 / 3	30 / 1		**815 / 68**	660 / 58	614 / 61
$N_d = 3, N_v = 1$	5 / 3	7 / 6	5 / 3	29 / 3	13 / 6	10 / 3		4 / 0	9 / 1
$N_d = 3, N_v = 2$	3 / 2	8 / 1	5 / 2	11 / 2	8 / 1	11 / 2	**150 / 7**		40 / 1
$N_d = 3, N_v = 3$	1 / 1	3 / 0	16 / 1	13 / 1	12 / 0	12 / 1	**190 / 6**	5 / 1	

N_d — номер набора данных, N_v — номер набора параметров запуска автоэнкодера

Классификация аномалий

- Из результатов всех экспериментов были отобраны все уникальные аномалии, получено:
  - **1587** аномалий по дереву разбора
  - **139** аномалий по байт-коду
- Было отобрано **103** наиболее показательных аномалии (удалены аномалии одного вида и дубликаты)
- Из полученных аномалий было выделено **30** классов*

* http://victor.am — список всех классов и аномалий

Сбор экспертных оценок

- По полученным аномалиям и классам были собраны экспертные оценки от разработчиков компилятора Kotlin

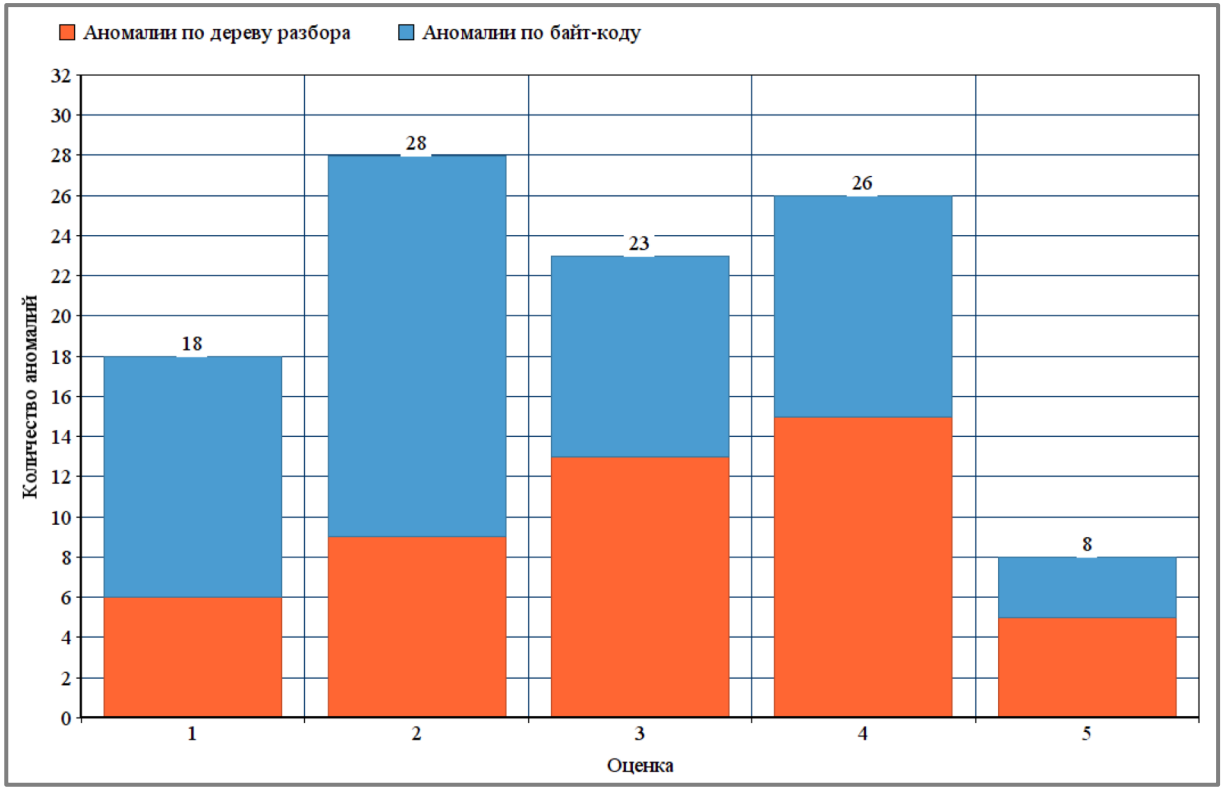

- Среднее по классам — **2.462**
- Среднее по аномалиям — **2.786**
  - По PSI — **3.083**
  - По байт-коду — **2.527**
- **12** классов с оценками 4 и 5
- **34** аномалии с оценками 4 и 5

Сравнение с похожей работой

- В похожей работе использовалось:
  - Факторизация путем явного извлечения признаков;
  - local outlier factor, elliptic envelope и isolation forest.

W_1 — настоящая работа, W_2 — похожая работа, V — оценка

Название класса	W_1	W_2	V
Много веток в when-выражении	+	+	
Много делегированных свойств	+	+	5
Много типовых параметров	+	+	
Большая иерархия вызовов	+		
Много if-выражений	+	+	
Большой набор констант	+		
Сложные аннотации функции		+	
Длинные цепочки вызовов	+		
Длинные перечисления (enum)	+		4
Необычные кодовые конструкции		+	
Сложная иерархия *enum*-классов	+		
Много аннотаций с кв. скобками	+		
Много схожих вызовов	+	+	
Много функций на уровне файла	+		
Сложная структура кода	+	+	
Большое тело функции	+	+	
Длинные строковые литералы	+		
Много конструкций try-catch		+	3
Много присваиваний	+		
Много послед. арифм. выражений	+		
Много параметров у функции	+		
Много операторов !!	+		
Много схожих фрагментов		+	
Много inline-функций	+		
Много опер. конкатенации	+		
Много ссылок на класс		+	
Много лямбда-выражений		+	
Много throw-операторов		+	2
Много reified тип. парам.	+		
Сложные лог. выражения	+		
Много циклов	+		
Большие литералы-коллекции	+		
Много локальных переменных		+	
Много вложенных функций		+	
Большой companion-объект	+		
Длинный init-метод	+		
Много null-безопасных вызовов	+		
Много преобразований типов		+	
Много пустых стр. литералов		+	1
Много строковых литералов	+	+	
Много строковых литералов		+	
Много вложенных структур	+		
Код из руководств по Kotlin		+	

Выводы

- Несмотря на невысокие оценки в целом, предложенный подход оказался вполне пригоден для поиска полезных кодовых аномалий

- Аномалии с оценками 4 и 5 были включены в тесты производительности компилятора Kotlin и, таким образом, внесли вклад в улучшение его качества

Написана и принята статья на конференцию ML4PL: Bryksin T., Petukhov V., Smirenko K., Povarov N. Detecting anomalies in Kotlin code

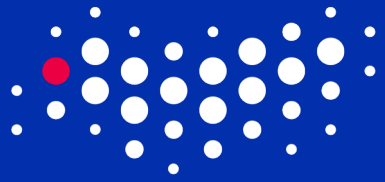

ITMO UNIVERSITY

Спасибо за внимание!

Петухов Виктор

Студент группы M4238

Кафедра Компьютерных технологий

Санкт-Петербург, 2018